



Unisport

Máster en Big Data e IA en el Deporte

ANÁLISIS PREDICTIVO APLICADO AL CONTROL DE CARGA EN FÚTBOL

INTEGRANTES:
Calviño García, Jacobo

3 de abril de 2026

Índice

1. Introducción	2
2. Generación del dataset	2
3. Exploración y limpieza de datos	3
4. Modelado predictivo	3
5. Evaluación del modelo	4
6. Interpretación de variables y recomendaciones	5
7. Conclusiones	6
8. Limitaciones	7

INTRODUCCIÓN

El objetivo de este trabajo es desarrollar un caso de análisis predictivo aplicado al ámbito deportivo a partir de un conjunto de datos ficticios, pero construido con criterios de realismo. El contexto elegido es el fútbol profesional, simulando la carga de trabajo de una plantilla de 23 jugadores a lo largo de varios microciclos de entrenamiento y competición.

El proceso seguido se ha dividido en cuatro fases: generación del dataset, exploración y limpieza de datos, modelado predictivo y evaluación del modelo. A diferencia de un conjunto generado de forma puramente aleatoria, el dataset construido incorpora restricciones tácticas y deportivas, como una formación fija 1-4-4-2 en partido, rotaciones probabilísticas, fatiga acumulada, carga previa, sueño, sesiones de gimnasio y campo, así como la aparición puntual de lesiones.

El propósito final no es predecir un resultado competitivo, sino identificar situaciones de **carga elevada**, entendidas como contextos de mayor exigencia física y, potencialmente, de mayor riesgo. Este enfoque resulta más estable que la predicción directa de lesión, ya que las lesiones son eventos muy escasos y difíciles de modelar en muestras pequeñas.

GENERACIÓN DEL DATASET

El dataset fue generado mediante Python y exportado en formato CSV para facilitar un flujo de trabajo reproducible en un entorno único. La plantilla simulada consta de 23 jugadores, con dorsales y posiciones asignadas de acuerdo con una estructura realista: dos porteros, varios defensas, centrocampistas y delanteros. El once inicial de cada partido no es fijo, sino que se selecciona mediante probabilidades de participación, respetando siempre una estructura táctica 1-4-4-2.

Se simularon 6 microciclos, cada uno compuesto por 8 sesiones: 7 entrenamientos y 1 partido. Las sesiones se clasificaron en Gym, Field, Match e Injury. Las variables principales generadas fueron:

- `player_id`: identificador del jugador.
- `position`: posición general del jugador (GK, DEF, MID, FWD).
- `session_type`: tipo de sesión.
- `duration_min`: duración de la sesión en minutos.
- `total_distance_m`: distancia total recorrida.
- `high_speed_running_m`: metros recorridos a alta velocidad.
- `sleep_hours`: horas de sueño previas.
- `prev_load`: carga previa acumulada.
- `rpe_load`: carga interna estimada.

Además, se introdujeron valores faltantes y outliers de forma intencional, con el objetivo de simular problemas habituales en datos reales, como fallos de sensor o errores de registro manual.

EXPLORACIÓN Y LIMPIEZA DE DATOS

El conjunto original contiene aproximadamente 1.100 observaciones, una cifra suficiente para realizar análisis descriptivo y entrenar modelos sencillos. En primer lugar, se verificó la coherencia estructural del dataset. Todos los partidos presentan exactamente 11 jugadores participantes y un único portero, respetando la formación definida en la simulación. También se comprobó que las sesiones de lesión aparecían como observaciones con carga nula y valores ausentes coherentes en las variables fisiológicas.

A nivel descriptivo, las variables de carga mostraron patrones lógicos. Las sesiones de partido concentraron los valores más altos de carga interna y externa, seguidas de las sesiones de campo, mientras que las sesiones de gimnasio presentaron demandas menores. Por posición, los centrocampistas y jugadores ofensivos tendieron a mostrar una mayor variabilidad, mientras que los porteros presentaron valores más bajos y estables.

Se detectaron valores faltantes, principalmente en `sleep_hours` y, en menor medida, en variables de carga externa. Dado que el porcentaje de valores ausentes era reducido, se optó por una imputación simple mediante la mediana. En cuanto a valores atípicos, se aplicó un criterio basado en el rango intercuartílico (IQR), recortando observaciones extremas sin eliminar filas completas. Esta decisión permitió conservar el volumen muestral y reducir el impacto de errores puntuales.




Figura 1: Correlación de las variables explicativas con la variable objetivo de carga alta.

Como se observa en la Figura 1, la carga elevada se relaciona sobre todo con variables de carga externa, especialmente la duración de la sesión, la distancia total y la distancia a alta velocidad. En cambio, `sleep_hours` presenta una relación negativa, lo que resulta coherente con un peor estado de recuperación.

MODELADO PREDICTIVO

Inicialmente se planteó la predicción directa de lesión, pero el número de eventos positivos resultó demasiado reducido para obtener un modelo estable. Por ello, se reformuló el problema como una tarea de clasificación

binaria orientada a detectar **situaciones de carga alta**. La variable objetivo se definió a partir del percentil 90 de `rpe_load`, de modo que las observaciones con carga interna especialmente elevada fueran etiquetadas como casos positivos.

Esta redefinición del target permitió transformar un problema excesivamente desbalanceado en otro más tratable, manteniendo además un sentido deportivo claro: no se intenta afirmar que una lesión vaya a producirse, sino identificar contextos de elevada exigencia que puedan requerir monitorización o intervención.

Como modelo predictivo se utilizó un **Random Forest Classifier**. La elección se justifica por varias razones: funciona bien sobre datos tabulares, es robusto frente a ruido y valores atípicos, permite capturar relaciones no lineales y facilita la interpretación a través de la importancia de variables. Además, se empleó validación cruzada de 5 particiones para evaluar la estabilidad del rendimiento.

Durante el desarrollo se detectó un problema inicial de *data leakage*, ya que una variable utilizada en la definición del target se había incluido también entre las variables de entrada. Tras eliminar ese solapamiento, el modelo pasó a ofrecer resultados realistas y generalizables.

Finalmente, se añadió una variable `acwr_proxy`, entendida como una aproximación simplificada al concepto de *Acute:Chronic Workload Ratio*. Dado que el dataset no incluía fechas explícitas, no era posible calcular el ACWR clásico mediante ventanas temporales. Como alternativa, se empleó una relación entre la carga actual y la carga previa, con el fin de capturar incrementos bruscos de carga. Aunque la mejora en el rendimiento fue moderada, esta variable aportó valor explicativo adicional.

EVALUACIÓN DEL MODELO

Los resultados obtenidos muestran un comportamiento sólido del modelo. En la partición de test, el clasificador alcanzó un AUC-ROC de 0.964 y un área bajo la curva Precision-Recall de 0.772, métricas especialmente relevantes en problemas con clases desbalanceadas. La matriz de confusión mostró un equilibrio razonable entre falsos positivos y falsos negativos, lo que indica que el modelo no se limita a predecir la clase mayoritaria.




Figura 2: Matriz de confusión.

Figura 3: Rendimiento del modelo en test.

La validación cruzada confirmó esta estabilidad. Las medias obtenidas fueron: $\text{accuracy} = 0.9364$, $\text{precision} = 0.6613$, $\text{recall} = 0.7541$, $F1 = 0.7023$ y $\text{ROC_AUC} = 0.9692$. Estos resultados sugieren que el modelo es consistente y no depende en exceso de una partición concreta de los datos.

También se analizó el comportamiento del modelo en función del umbral de decisión. El mejor equilibrio entre precisión y recall se obtuvo en torno a un umbral de 0.35, con un F1-score máximo cercano a 0.67. Desde un punto de vista aplicado, esto significa que puede ajustarse el umbral según el objetivo del cuerpo técnico: priorizar una mayor detección de casos potencialmente problemáticos o reducir falsas alarmas.




Figura 4: Curva Precision-Recall del modelo.

La Figura 4 resulta especialmente útil porque refleja mejor el comportamiento del modelo en un escenario con desbalanceo que la accuracy por sí sola. El rendimiento obtenido indica que el sistema es capaz de concentrar una parte importante de los casos de carga alta en los niveles superiores de riesgo predicho.

INTERPRETACIÓN DE VARIABLES Y RECOMENDACIONES

La importancia de variables muestra que la duración de la sesión es el factor más influyente, seguida de la distancia total recorrida y la distancia a alta velocidad. Esto confirma que la carga externa es el principal determinante de la clasificación de alta carga. A continuación aparece `acwr_proxy`, lo que sugiere que no solo importa la cantidad absoluta de trabajo, sino también cómo cambia respecto a la carga previa.




Figura 5: Importancia relativa de las variables del modelo.

A partir de estos resultados pueden plantearse varias recomendaciones prácticas:

- Monitorizar especialmente las sesiones largas con alta distancia total y alta exposición a carrera de alta velocidad.
- Prestar atención a cambios bruscos entre la carga previa y la carga actual, ya que pueden aumentar el riesgo asociado.
- Utilizar el modelo como herramienta de apoyo para decidir cuándo conviene modular la carga de un jugador.
- Considerar el sueño como variable contextual de recuperación, especialmente en sesiones de mayor exigencia.

El modelo no sustituye el juicio técnico, pero sí puede servir como sistema de alerta temprana para identificar sesiones o jugadores que requieran una observación más detallada.

CONCLUSIONES

El trabajo ha permitido construir un pipeline completo de análisis predictivo en deporte, desde la simulación de datos hasta la evaluación de un modelo de clasificación. El dataset generado presenta una estructura coherente con la realidad del fútbol profesional, incorporando elementos como formación táctica, rotaciones, carga acumulada, sueño y lesiones.

Tras una primera aproximación orientada a la predicción de lesión, se comprobó que la baja frecuencia de este evento dificultaba la obtención de resultados útiles. La redefinición del problema como detección de situaciones de carga alta permitió entrenar un modelo mucho más estable y aplicable. El Random Forest mostró un rendimiento sólido, con métricas elevadas y consistentes en validación cruzada.

La incorporación de una aproximación al ACWR aportó una mejora moderada pero relevante, reforzando la idea de que en el deporte no solo importa la carga absoluta, sino también la variación de dicha carga respecto a la

carga habitual. En conjunto, el modelo desarrollado constituye una herramienta útil para la monitorización del entrenamiento y para apoyar decisiones preventivas en contextos deportivos.

LIMITACIONES

La principal limitación del trabajo es el carácter sintético del dataset. Aunque se ha buscado un alto grado de realismo, los datos no proceden de un entorno competitivo real y, por tanto, no recogen toda la complejidad del rendimiento deportivo. Además, la aproximación al ACWR no reproduce exactamente la formulación clásica basada en ventanas temporales reales, debido a la ausencia de fechas explícitas en la base de datos.

Como líneas futuras, sería interesante trabajar con datos reales longitudinales, incorporar más variables fisiológicas y comparar diferentes algoritmos de clasificación para evaluar si el rendimiento puede seguir mejorando.